



UNIVERSIDAD TECNOLÓGICA NACIONAL

Facultad Regional Córdoba

Ingeniería en Sistemas de Información

Cátedra: Ciencia de Datos

TRABAJO PRÁCTICO INTEGRADOR

Docentes:

Maldonado, Calixto | Callejas, Marisa | Oliva, Sebastián

Año 2026 – Curso 5K4

Grupo 15:

- Franco, Recalde - 94661
- Emilio, Sadir - 96622
- Rodríguez, Joaquín Ignacio - 85406
- Noto, Claudia Carina - 95215
- Monteros, Leandro Ignacio - 90258
- Ferraro, Ayelen - 99149
- Chiaro, Tiziano - 90043
- Bailey, Julián Eduardo - 96032



Índice de Contenidos

Índice de Contenidos	2
1. Plan de Proyecto	3
1.1 Objetivo del Proyecto	3
1.2 Alcance	3
1.3 Metodología: Scrum Ágil	4
1.4 Roles del Equipo Scrum	4
1.5 Product Backlog y Plan de Sprints	4
1.6 Calendario	5
2. Selección del Dataset	6
2.1 Contexto del Dominio	6
2.2 Fuente de Datos	6
2.3 Descripción del Dataset	6
2.3.1 Descripción de Variables del Dataset	7
Organización de columnas	7
Datos sensoriales de cada IMU	7
Catálogo de actividades (activityID)	7
2.4 Justificación de la Elección	8



1. Plan de Proyecto

1.1 Objetivo del Proyecto

El presente proyecto tiene como objetivo analizar datos de monitoreo de actividad física provenientes del dataset PAMAP2 (Physical Activity Monitoring), disponible en el UCI Machine Learning Repository, con el fin de identificar patrones de movimiento y reconocer actividades físicas a partir de señales de sensores inerciales y frecuencia cardíaca. El dataset comprende registros de 9 sujetos equipados con 3 unidades de medición inercial (IMU) y un monitor de frecuencia cardíaca, realizando 12 actividades físicas distintas. Mediante la aplicación del ciclo de vida completo de un proyecto de Ciencia de Datos —desde la obtención y limpieza de los datos hasta el modelado predictivo— se busca generar conocimiento accionable que permita clasificar actividades humanas a partir de datos sensoriales. Los resultados serán presentados a través de una narrativa de datos (Data Storytelling) que comunique los hallazgos de manera clara y rigurosa.

1.2 Alcance

El proyecto comprende las siguientes actividades:

- Obtención, evaluación y selección del dataset PAMAP2 (UCI ML Repository), unificación de archivos por sujeto y reducción de frecuencia de muestreo de 100Hz a 10Hz.
- Preprocesamiento y limpieza de datos (ETL): tratamiento de valores faltantes, inconsistentes o erróneos.
- Análisis exploratorio y estadístico de las variables sensoriales y fisiológicas seleccionadas.
- Análisis de relaciones entre variables y visualización de patrones.
- Entrenamiento, evaluación y ajuste de modelos de Machine Learning para clasificación de actividades físicas según las hipótesis definidas.
- Documentación del proceso en formato de paper científico.
- Presentación final con metodología de Data Storytelling.

El proyecto no incluye:

- Desarrollo de aplicaciones web, móviles o firmware para dispositivos wearable.
- Análisis de señales biomédicas fuera del alcance de los sensores IMU utilizados.
- Procesamiento de señales en tiempo real ni integración con hardware de sensores.

1.3 Metodología: Scrum Ágil

El proyecto se gestiona aplicando el framework Scrum con sprints de duración semanal. Las ceremonias previstas son: Sprint Planning (al inicio de cada sprint), Daily Scrum (comunicación asíncrona vía grupo de WhatsApp, dada la disponibilidad dispar de los integrantes), Sprint Review y Sprint Retrospective al cierre de cada sprint. Los entregables académicos actúan como incrementos formales del producto.

1.4 Roles del Equipo Scrum

La estructura de roles del equipo es la siguiente:



Rol	Integrante(s)	Responsabilidades
Product Owner	Franco Recalde	Define prioridades, coordina con docentes y valida entregables.
Scrum Master	Emilio Sadir	Facilita reuniones, asegura alineación del equipo y elimina bloqueos.
Equipo de Desarrollo	Todos los integrantes	Obtención de datos, limpieza, análisis, modelado, visualización y presentación.

1.5 Product Backlog y Plan de Sprints

A continuación se detalla el plan de sprints, con sus etapas, estado actual y actividades principales. El Sprint 1 se encuentra completado (Primera Entrega). Los sprints subsiguientes se ejecutarán conforme al calendario académico establecido por la cátedra.

Sprint	Etapa	Estado	Actividades principales
Sprint 1	Planificación y datos	Completado	Definición del plan de proyecto, asignación de roles, selección del dataset, revisión y comprensión de los datos. Primera entrega.
Sprint 2	ETL	En curso	Limpieza y transformación de datos. Análisis estadístico exploratorio. Identificación y tratamiento de valores faltantes, erróneos e inconsistentes. Preparación del dataset objetivo.
Sprint 3	Análisis de variables	Pendiente	Análisis de relaciones entre variables. Generación de visualizaciones. Confirmación/refinamiento de hipótesis.
Sprint 4	Modelado	Pendiente	Selección de algoritmos, entrenamiento y ajuste de modelos de ML para las tres hipótesis.
Sprint 5	Evaluación y cierre	Pendiente	Métricas de evaluación, validación cruzada, ajuste final, interpretación de resultados y presentación final.

1.6 Calendario

La planificación temporal del proyecto es la siguiente:

#	Período	Actividad
1	Semana del 14/04/2026	Sprint 1 – Primera entrega (completada)
2	Semana del 21/04/2026	Sprint 1 – ETL: Exploración inicial y análisis de calidad
3	Semana del 28/04/2026	Sprint 2 – ETL: Limpieza y transformación
4	Semana del 05/05/2026	Sprint 2 – ETL: Preparación dataset objetivo. Segunda entrega
5	Semana del 12/05/2026	Sprint 3 – Análisis de variables y visualizaciones
6	Semana del 19/05/2026	Sprint 3 – Refinamiento de hipótesis
7	Semana del 26/05/2026	Sprint 4 – Modelado: selección de algoritmos y entrenamiento
8	Semana del 02/06/2026	Sprint 4 – Modelado: ajuste y evaluación. Tercera entrega
9	Semana del 09/06/2026	Sprint 5 – Interpretación de resultados
10	Semana del 16/06/2026	Sprint 5 – Presentación final (Data Storytelling)



2. Selección del Dataset

2.1 Contexto del Dominio

El monitoreo de actividad física mediante sensores corporales (wearable sensors) es un área de creciente relevancia en el ámbito de la salud, el deporte y la rehabilitación. El reconocimiento automático de actividades (Human Activity Recognition, HAR) permite determinar qué tipo de ejercicio o movimiento realiza una persona a partir de señales inerciales y fisiológicas, sin necesidad de observación directa. Comprender los patrones de movimiento que caracterizan distintas actividades —ya sean estáticas, dinámicas o de transición— es un problema de alto valor práctico y una tarea desafiante desde el punto de vista del análisis de datos, dado el volumen de muestras generadas por sensores de alta frecuencia, la variabilidad inter-sujeto y la complejidad multidimensional de las señales involucradas.

La disponibilidad de datasets de referencia como PAMAP2 permite abordar este problema con técnicas de Machine Learning supervisado, principalmente de clasificación (predecir qué actividad física se está realizando a partir de las lecturas de los sensores). Este dominio resulta especialmente adecuado para un proyecto de Ciencia de Datos de nivel académico avanzado, dado que combina desafíos reales de calidad de datos (valores faltantes por desconexiones inalámbricas, diferencias entre sensores), volumen considerable y objetivos de modelado bien definidos.

2.2 Fuente de Datos

El dataset seleccionado es el PAMAP2 Physical Activity Monitoring Dataset, publicado en el UCI Machine Learning Repository por A. Reiss y D. Stricker (Sensor Technology Department, German Research Center for Artificial Intelligence – DFKI). El mismo contiene datos de monitoreo de actividad física recopilados mediante 3 unidades de medición inercial (IMU) Colibri y un monitor de frecuencia cardíaca, con una frecuencia de muestreo original de 100Hz para las IMU y ~9Hz para el monitor cardíaco. Los datos fueron recopilados de 9 sujetos (8 hombres y 1 mujer) realizando 18 actividades físicas distintas. Para este trabajo se unifican los archivos de todos los sujetos y se aplica un downsampling a 10Hz. El dataset está disponible en el siguiente enlace:

<https://archive.ics.uci.edu/dataset/231/pamap2+physical+activity+monitoring>

2.3 Descripción del Dataset

El dataset está organizado por sujeto, con archivos de texto separados para cada uno de los 9 participantes (subject101.dat a subject109.dat). Cada archivo contiene registros individuales de lecturas sensoriales con un timestamp, el identificador de la actividad realizada, la frecuencia cardíaca y los datos de las 3 IMU (mano, pecho y tobillo), incluyendo aceleración, giroscopio, magnetómetro y orientación. **Para este trabajo se unifican los archivos de todos los sujetos en un único dataset consolidado, aplicando un downsampling de 100Hz a 10Hz.** El dataset original contiene más de 3.850.000 registros (sumando todos los sujetos a 100Hz); tras la unificación y el downsampling a 10Hz, el dataset resultante comprende aproximadamente 194.000 registros, lo que supera ampliamente el mínimo de 20.000 filas requerido y mantiene una escala manejable para las etapas de ETL y modelado.

Característica	Detalle
Fuente	UCI Machine Learning Repository / DFKI, Alemania
Período cubierto	2012 (9 sujetos, 18 actividades físicas)



Registros utilizados	~194.000 filas (9 sujetos unificados, downsampling a 10Hz)
Formato	DAT/CSV (archivo por sujeto, unificado en CSV)
Variables (columnas)	54 columnas (timestamp, activityID, heart_rate + 51 variables sensoriales de 3 IMU)
Tipo de datos	Numérico continuo (sensores), categórico (activityID, subjectID), temporal (timestamp)
Licencia	Creative Commons Attribution 4.0 International (CC BY 4.0)

2.3.1 Descripción de Variables del Dataset

2.3.1.1 Organización de columnas

Las 54 columnas de los archivos de datos están organizadas de la siguiente manera:

1. timestamp (s)
2. activityID (ver catálogo de actividades en 2.3.1.3)
3. heart rate (bpm)
- 4–20. IMU hand (mano dominante)
- 21–37. IMU chest (pecho)
- 38–54. IMU ankle (tobillo dominante)

2.3.1.2 Datos sensoriales de cada IMU

Cada una de las tres IMU (mano, pecho, tobillo) proporciona 17 columnas con la siguiente estructura:

1. temperature (°C)
- 2–4. 3D-acceleration data (ms^{-2}), scale: $\pm 16\text{g}$, resolution: 13-bit
- 5–7. 3D-acceleration data (ms^{-2}), scale: $\pm 6\text{g}$, resolution: 13-bit
- 8–10. 3D-gyroscope data (rad/s)
- 11–13. 3D-magnetometer data (μT)
- 14–17. orientation (invalid in this data collection)

Nota: según la documentación oficial del dataset, los datos de orientación (columnas 14–17 de cada IMU) no son válidos en esta recolección de datos y deberían ser descartados o tratados con precaución en el análisis.

2.3.1.3 Catálogo de actividades (activityID)

La siguiente tabla presenta el mapeo entre los identificadores numéricos (activityID) y las actividades correspondientes, tal como se define en la documentación oficial del dataset:

- 1 – lying (acostado)
- 2 – sitting (sentado)
- 3 – standing (de pie)
- 4 – walking (caminando)
- 5 – running (corriendo)
- 6 – cycling (ciclismo)
- 7 – Nordic walking
- 9 – watching TV
- 10 – computer work
- 11 – car driving
- 12 – ascending stairs (subiendo escaleras)
- 13 – descending stairs (bajando escaleras)
- 16 – vacuum cleaning (aspirando)



- 26. 17 – ironing (planchando)
- 27. 18 – folding laundry
- 28. 19 – house cleaning
- 29. 20 – playing soccer
- 30. 24 – rope jumping (saltar la cuerda)
- 31. 0 – other (transient activities / actividades transitorias)

Las actividades 1–7 y 12–13 forman parte del protocolo estándar que siguieron todos los sujetos. Las actividades 9, 10, 11, 16–20 y 24 son opcionales y no fueron realizadas por todos los participantes. El activityID 0 corresponde a períodos transitorios entre actividades, los cuales fueron excluidos del dataset de trabajo.

2.4 Justificación de la Elección

El dataset fue seleccionado por los siguientes motivos:

- Volumen suficiente y representativo: el dataset consolidado a 10Hz comprende aproximadamente 194.000 registros distribuidos entre 9 sujetos y 12 actividades del protocolo estándar, suficientes para obtener resultados estadísticamente sólidos y para entrenar modelos de Machine Learning con validez.
- Variedad de variables: la combinación de variables inerciales (acelerómetro, giroscopio, magnetómetro), fisiológicas (frecuencia cardíaca) y de orientación, distribuidas en tres posiciones corporales (mano, pecho, tobillo), habilita el planteo de múltiples hipótesis y la aplicación de distintos paradigmas de modelado.
- Calidad de la fuente: los datos provienen del DFKI (German Research Center for Artificial Intelligence) y han sido publicados en conferencias académicas de referencia (IEEE ISWC 2012), lo que garantiza su confiabilidad y rigor metodológico. Relevancia práctica: el reconocimiento de actividad física es un problema real con impacto directo en salud, rehabilitación y desarrollo de dispositivos wearable, lo que dota al proyecto de valor más allá del ejercicio académico.
- Idoneidad para ML supervisado: la disponibilidad de variables objetivo bien definidas (activityID) facilita el diseño de experimentos de clasificación supervisada con resultados interpretables.
- Viabilidad computacional y acotamiento del análisis: dado que el dataset original a 100Hz supera los 3.850.000 registros, se optó por aplicar un downsampling a 10Hz —frecuencia ampliamente utilizada en la literatura de HAR— lo que reduce el volumen a ~194.000 registros sin pérdida significativa de información relevante para el reconocimiento de actividades. Se conservan los 9 sujetos para garantizar representatividad y capacidad de generalización del modelo.



SPRINT 2 - ETL

Índice:



Hipótesis:	2
Objetivo del Proceso.....	3
Extracción y Unificación (Extract).....	4
Transformación y Limpieza (Transform).....	4
Carga (Load).....	6

Hipótesis:

1. Existe una correlación positiva y cuantificable entre la frecuencia cardíaca media del sujeto y el nivel de intensidad de la actividad física clasificada (baja, moderada y vigorosa).
2. Las actividades dinámicas de alto impacto físico (ej. correr, saltar) presentan una varianza significativamente mayor en la magnitud del vector de frecuencia cardíaca en comparación con las actividades estáticas o de rutina doméstica.



3. Las características basadas en la velocidad angular, extraídas específicamente del giroscopio posicionado en la mano, poseen una mayor capacidad predictiva (Feature Importance) que los datos de aceleración lineal al momento de clasificar actividades que involucran motricidad fina o tareas del tren superior (como planchar o realizar labores domésticas).



Objetivo del Proceso

El objetivo principal del script es la implementación de un pipeline **ETL** (Extract, Transform, Load) desarrollado en Python para procesar el conjunto de datos PAMAP2 (Physical Activity Monitoring Dataset). Este proceso busca depurar, consolidar y optimizar los datos capturados por sensores inerciales y monitores de ritmo cardíaco, preparándolos para la posterior fase de entrenamiento de modelos de Machine Learning.


Extracción y Unificación (Extract)

- **Ingesta de Datos:** Se cargaron los 9 archivos en formato *.dat* pertenecientes al protocolo estándar (sujetos 101 a 109).
- **Configuración del Entorno:** Detectamos automáticamente si nuestro dataset se ejecuta en Google o localmente.
- **Estructuración Base:** Como los archivos fuente carecían de cabeceras, mapeamos manualmente las 54 columnas originales a nombres descriptivos en español.
- **Trazabilidad:** Incorporamos el atributo “*sujeto_id*” al momento de la extracción, un campo vital para poder implementar la técnica de validación cruzada LOSO-CV (Leave-One-Subject-Out) en etapas posteriores.



Transformación y Limpieza (Transform)

Esta etapa se aplicaron una serie de técnicas para aumentar la calidad de la información, reducir la dimensionalidad y eliminar el ruido:

- **Downsampling (Submuestreo):** La frecuencia original de las IMU (100 Hz) se redujo a 10 Hz extrayendo 1 fila de cada 10, agrupando de manera independiente por sujeto y actividad. Esto logró una reducción del volumen de registros (de ~3.8M a ~194K) manteniendo la información de los patrones de movimiento humano relevantes (que oscilan por debajo de los 6 Hz).




- **Manejo de Valores Faltantes (NaNs):** Detectamos que el 91% de los registros de “*frecuencia_cardiaca*” eran nulos estructurales causados por la baja frecuencia de captura del pulsómetro frente a los acelerómetros. Esto lo solucionamos aplicando una interpolación lineal por sujeto, complementada con métodos de propagación *ffill* y *bfill* en los extremos.
 - Las filas con nulos remanentes en otras columnas fueron descartadas (*dropna*) para asegurar la integridad de la muestra.



- **Depuración de Columnas Inválidas:** Eliminamos 12 columnas asociadas a la orientación de los componentes IMU (mano, pecho y tobillo) por fallos de calibración documentados por los autores originales del dataset.
- **Exclusión de Registros Transitorios:** Filtramos todos los registros asociados a la “*actividad_id = 0*”, la cual representaba movimientos transitorios y de transición que generaban ambigüedades de clasificación.
- **Casteo y Validación:** Los atributos de identificación los transformamos a números enteros y se verificó mediante lógicas de negocio que todos los registros estuvieran dentro del catálogo de actividades aceptadas y dentro de los rangos fisiológicos o físicos posibles.

Variable	Rango esperado
frecuencia_cardiaca	40 – 220 bpm
*_temperatura	20 – 42 °C
*_acel1_x/y/z	–200 a 200 m/s ²
*_acel2_x/y/z	–80 a 80 m/s ²
*_giro_x/y/z	–35 a 35 rad/s

- **Normalización de los datos:** Utilizamos la aplicación **StandardScaler** (Z-score) para uniformar escalas (bpm , m/s^2 , rad/s).
- **Outlier por actividad:** Se observó que el dataset se encuentra desbalanceado, con una mayor representación de actividades de baja intensidad (como caminar o lavar los platos) frente a las de alta intensidad (como correr o saltar la soga). Para evitar que los registros legítimos de las actividades intensas fueran erróneamente descartados al alejarse de la media global, se decidió realizar la detección de valores atípicos agrupando por actividad. La regla utilizada consistió en eliminar toda fila donde al menos una de las variables clave cayera fuera del rango $[Q1 - 1,5 \times \text{IQR}, Q3 + 1,5 \times \text{IQR}]$ para su actividad correspondiente.



Carga (Load)

- **Estrategia de Salida:** El set de datos transformado se consolidó en un único archivo llamado *"pamap2_limpio.csv"* en el directorio *"data/processed/"*.
- **Método de Escritura:** Optamos por una carga completa (*Batch*) en modalidad de sobreescritura (*Overwrite*). Esta estrategia está fundamentada operativamente en que el dataset es estático, no recibe nuevos datos transaccionales y posee un tamaño manejable en memoria (~130 MB), lo que hace innecesario establecer cargas incrementales o realizar un particionado complejo.