

Sprint 3 - Fase de Modelado y Clasificación

Proyecto: Trabajo Práctico Integrador — **Entrega 3**

Equipo: Grupo 15 | Ciencia de Datos 2026 | UTN FRC

Índice:

1. Objetivo y Estrategia de Validación.....	2
2. Validación de la Hipótesis 1 (H1).....	2
3. Evaluación Exhaustiva de Algoritmos (Target: actividad_id).....	2
4. Elección y Justificación del Modelo Ganador.....	3
5. Oportunidades de Mejora.....	3

1. Objetivo y Estrategia de Validación

El objetivo exclusivo de esta entrega fue la aplicación de técnicas de Machine Learning para clasificar el tipo de actividad física y validar hipótesis correlacionales.

Para asegurar la robustez de las métricas, se descartó el *split* aleatorio tradicional y se implementó una partición **LOSO-CV parcial (Leave-One-Subject-Out)**. Los registros de los sujetos 102, 106 y 108 fueron aislados enteramente para conformar el conjunto de prueba (test set). Esta estrategia garantiza que los modelos sean evaluados por su capacidad para generalizar patrones de movimiento en "personas nuevas", impidiendo que memoricen la biometría específica de los participantes presentes en el entrenamiento.

2. Validación de la Hipótesis 1 (H1)

- **Hipótesis:** "Existe una correlación positiva y cuantificable entre la frecuencia cardíaca media del sujeto y el nivel de intensidad de la actividad física clasificada".
- **Resolución:** Se entrenaron modelos de Regresión Lineal y Logística sobre la variable objetivo `nivel_intensidad`. La hipótesis resultó estadísticamente **confirmada** mediante la Regresión Logística, la cual alcanzó un coeficiente de determinación R^2 de 0.7231 y una alta correlación de Pearson (0.8519).

3. Evaluación Exhaustiva de Algoritmos (Target: `actividad_id`)

Para el problema principal (clasificar 12 actividades utilizando 49 dimensiones derivadas de los sensores IMU), el equipo evaluó un amplio abanico de paradigmas algorítmicos:

- **Modelos Lineales (Regresión Logística y LinearSVC):** Fueron utilizados como la línea base del estudio. Su rendimiento fue deficiente (LinearSVC alcanzó un F1-Macro de 0.6482). Esto demostró empíricamente que un hiperplano lineal es matemáticamente insuficiente para separar la complejidad y superposición de las fronteras de decisión asociadas al movimiento humano.
- **Modelos Probabilísticos (Naive Bayes):** Si bien destacó por su extrema velocidad computacional, su capacidad predictiva se vio comprometida. Esto ocurre porque Naive Bayes parte de la fuerte asunción de que las variables predictoras son independientes; una condición probadamente falsa en este contexto, ya que las señales de los ejes X, Y, Z provenientes de un mismo acelerómetro anatómico están intrínsecamente correlacionadas.
- **Modelos Basados en Instancias (K-Nearest Neighbors):** Se evaluó con un hiperparámetro de $K=5$. Aunque el algoritmo de vecinos más cercanos logró captar relaciones no lineales, fue descartado como modelo principal debido al elevado costo computacional que exige calcular distancias en alta dimensionalidad durante la fase de inferencia.
- **Árboles de Decisión Individuales (Decision Tree):** Evaluado con una profundidad restringida (`max_depth=5`), el árbol individual exhibió una severa limitación para

generalizar, cayendo en un fuerte sobreajuste. Evidenció que un clasificador simple carece de la robustez requerida para modelar las variables biomecánicas.

- **Ensamblados de Boosting Secuencial (XGBoost):** Pese a ser un algoritmo de última generación optimizado por gradiente, en esta iteración XGBoost obtuvo un F1-Macro bajo (0.5337). Frente a la topología de los datos sensados, resultó superado ampliamente por los ensambles paralelos.
- **Ensamblados de Bagging (Random Forest y Extra Trees):** Esta familia de algoritmos dominó las métricas de evaluación. Random Forest corrigió las falencias del árbol individual promediando múltiples estimadores, pero fue la variante **Extra Trees** la que obtuvo los mejores resultados globales.

4. Elección y Justificación del Modelo Ganador

El modelo definitivo seleccionado para la Entrega 3 fue el clasificador **Extra Trees (Extremely Randomized Trees)**, alcanzando una Exactitud del 76.54% y un F1-Macro de 0.7310.

Justificación Técnica: La principal diferencia de Extra Trees radica en que no evalúa el "mejor" punto de corte temporal u óptimo para separar los datos en cada nodo de sus árboles, sino que elige los umbrales de partición de forma *completamente aleatoria*. En este proyecto particular, esta aleatoriedad extrema actuó como un poderoso mecanismo de regularización. Diluyó el sesgo introducido por los hábitos de movimiento idiosincrásicos del conjunto de entrenamiento, permitiendo que el modelo detecte los patrones de movimiento puros de cada actividad y logre clasificar exitosamente a los nuevos individuos del conjunto de prueba.

5. Oportunidades de Mejora

Como cierre de la iteración de modelado, se identificaron las siguientes oportunidades de mejora:

1. **Validación LOSO Completa:** Expandir el testeo iterativo hacia los 8 sujetos posibles (promediando las métricas), en lugar de limitarse a 3 sujetos fijos.
2. **Definición de Target:** El mapeo original de intensidades físicas posee un margen de subjetividad inherente impuesto por el equipo.
3. **Ausencia de Perspectiva Temporal:** El pipeline actual asume que cada fila a 10 Hz es un evento independiente. Futuras implementaciones deberían incorporar arquitecturas de Deep Learning secuencial (como redes LSTM o TCN) acopladas a ventanas temporales (*sliding windows*) para explotar la dinámica y continuidad del movimiento humano a lo largo del tiempo.